

**Домашнее задание по курсу “Теория вероятностей и математическая статистика”**

**ОП “Бизнес-информатика”**

**Выполнил**

**Кузнецов Вадим Олегович ББИ212**

**Вариант 10**

**Задание 1.**

*Рассчитайте выборочное среднее, смещенную оценку выборочной дисперсии, несмещенную оценку выборочной дисперсии, минимальное и максимальное значения в выборке.*

Решение:

$n = 1000$

Формула выборочного среднего:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Значение каждого  $x_i$  дано в таблице, рассчитаем в “HomeWork\_Kuznetsov.pynb”.

Получим  $\bar{x} = 7.590100102044744$

Формула смещенной оценки выборочной дисперсии:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Получили, что сумма равна 170558.6411818631, умножим на 1 / 1000.

Тогда  $s^2 = 170.5586411818631$ .

Формула несмещенной оценки выборочной дисперсии:

$$\widehat{\sigma^2} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Получили, что сумма равна 170558.6411818631, умножим на 1 / 999.

Тогда  $\widehat{\sigma^2} = 170.7293705524155$ .

Минимальное значение нашли по формуле `.min()`, аналогично с максимальным (`.max()`)


$\min = -33.26398528367281$

$\max = 49.64002200216055$

**Задание 2.**

*Постройте гистограмму. Предположите закон распределения генеральной совокупности, из которой была получена выборка. Обоснуйте ответ*

Решение:



Предположим, что это в генеральной совокупности нормальный закон распределения, так как видно распределение с пиком в центре и симметричными боковыми сторонами, что соответствует описанию нормального распределения.

**Далее предположим, что выборка получена из нормальной генеральной совокупности  $N(\mu, \sigma^2)$ .**

### Задание 3.

*Постройте 95% доверительный интервал для математического ожидания.*

*а) выпишите формулу доверительного интервала, которую будете использовать.*

*Поясните почему именно такую формулу выбрали;*

*б) выпишите критическое значение статистики.*

Решение:

Пусть наша величина генеральной совокупности распределена нормально, учитывая, что дисперсия неизвестна.

Тогда по данным выборки можно строить случайную величину, которая имеет распределение Стьюдента с  $n - 1$  степенями свободы.

$$\frac{\bar{x} - \mu}{\frac{\hat{\sigma}}{\sqrt{n}}} \sim t_{n-1}$$

Формула:

$$\left( t_{n-1, \frac{\alpha}{2}} \leq \frac{\bar{x} - \mu}{\frac{\hat{\sigma}}{\sqrt{n}}} \leq t_{n-1, 1-\frac{\alpha}{2}} \right) = 0.95$$

Само распределение Стьюдента с  $k$  степенями свободы выглядит следующим образом:

Пусть  $Z$  – случайная величина, имеющая стандартное нормальное распределение,  $Y$  – с.в., распределённая по закону хи-квадрат с  $k$  степенями свободы,  $Z$  и  $Y$  независимы. Пусть

$$U = \frac{Z}{\sqrt{\frac{1}{k}Y}}.$$

Рассмотрим величину  $U = \frac{\bar{X} - \mu}{(\hat{\sigma} / \sqrt{n})}$ . Иначе её можно представить так:

$$U = \frac{\left( \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \right)}{\sqrt{\frac{1}{n-1} \left( \frac{(n-1)\hat{\sigma}^2}{\sigma^2} \right)}}$$

Теперь в выражении есть истинная дисперсия наряду с выборочной. Выше уже говорилось, что  $\hat{\sigma}^2$  и  $\bar{X}$  независимы, а значит, независимы числитель и знаменатель этой дроби. В числителе стоит случайная величина, имеющая стандартное нормальное распределение, а в знаменателе – число  $1/(n-1)$ , умноженное на случайную величину, имеющую хи-квадрат распределение с  $(n-1)$  степенью свободы. Таким образом, величина  $U$  имеет распределение Стьюдента.

Б) Найдем же теперь критическое значение статистики

$$P\left(t_{n-1, 1-\frac{\alpha}{2}} \leq \frac{\bar{x} - \mu}{\frac{\hat{\sigma}}{\sqrt{n}}} \leq t_{n-1, \frac{\alpha}{2}}\right) = 0.95$$

$$1 - \alpha = 0.95$$

$$\alpha = 0.05$$

Выясним критические значения распределения Стьюдента с 999 степенями свободы

$$t_{999, 0.025} = 1.962341461133449$$

$$t_{999, 0.975} = -1.962341461133449$$

$$P\left(\bar{x} - t_{n-1, \frac{\alpha}{2}} * \frac{\hat{\sigma}}{\sqrt{n}} \leq \mu \leq \bar{x} - t_{n-1, 1-\frac{\alpha}{2}} * \frac{\hat{\sigma}}{\sqrt{n}}\right) = 0.95$$

$$P\left(\bar{x} - t_{999, 0.025} * \frac{\hat{\sigma}}{\sqrt{n}} \leq \mu \leq \bar{x} - t_{999, 0.975} * \frac{\hat{\sigma}}{\sqrt{n}}\right) = 0.95$$

$$P(6.779272173212221 \leq \mu \leq 8.400928030877267) = 0.95$$

Ответ:  $6.779272173212221 \leq \mu \leq 8.400928030877267$

#### Задание 4.

Постройте 95% доверительный интервал для дисперсии.

а) выпишите формулу доверительного интервала, который будете использовать.

Поясните почему именно такую формулу выбрали;

б) выпишите критическое значение статистики.

$$P(\chi^2_{(n-1), 1-\frac{\alpha}{2}} \leq \frac{(n-1) * \hat{\sigma}^2}{\sigma^2} \leq \chi^2_{(n-1), \frac{\alpha}{2}}) = 0.95$$

$$P\left(\frac{(n-1)\hat{\sigma}^2}{\chi_{n-1,\alpha/2}^2} < \sigma^2 < \frac{(n-1)\hat{\sigma}^2}{\chi_{n-1,1-\alpha/2}^2}\right) = 0.95$$

Пусть наша величина генеральной совокупности распределена нормально, учитывая, что дисперсия неизвестна. Тогда по данным выборки можно строить случайную величину, имеющую хи-квадрат распределение с  $k$  степенями свободы. Очевидно, что

$$P(\chi_{k,1-\alpha/2}^2 < \chi_k^2 < \chi_{k,\alpha/2}^2) = 1 - \alpha.$$

Известно, что в случае нормальной генеральной совокупности случайная величина  $\frac{(n-1)\hat{\sigma}^2}{\sigma^2}$  имеет хи-квадрат распределение со степенями свободы  $n-1$ . Таким образом,

$$\begin{aligned} 1 - \alpha &= P(\chi_{n-1,1-\alpha/2}^2 < \chi_{n-1}^2 < \chi_{n-1,\alpha/2}^2) = P(\chi_{n-1,1-\alpha/2}^2 < \frac{(n-1)\hat{\sigma}^2}{\sigma^2} < \chi_{n-1,\alpha/2}^2) = \\ &= P\left(\frac{(n-1)\hat{\sigma}^2}{\chi_{n-1,\alpha/2}^2} < \sigma^2 < \frac{(n-1)\hat{\sigma}^2}{\chi_{n-1,1-\alpha/2}^2}\right). \end{aligned}$$

Б) Расчитаем

$$\chi_{n-1,\frac{\alpha}{2}}^2 = 1088.4870677259353$$

$$\chi_{n-1,1-\frac{\alpha}{2}}^2 = 913.3009983021134$$

$$P(156.69330967633252 \leq \sigma^2 \leq 186.74964934774277) = 0.95$$

Ответ:  $156.69330967633252 \leq \sigma^2 \leq 186.74964934774277$

## Задание 5.

Проверьте гипотезу о равенстве математического ожидания нулю. Используйте двустороннюю альтернативу и уровень значимости 10%.

а) сформулируйте основную и альтернативную гипотезы;

б) выпишите расчетную статистику. Почему была выбрана именно такая статистика?

А) Сформулируем гипотезы

$H_0: \mu_0 = 0$

$H_1: \mu_0 \neq 0$  (так как используем двустороннюю альтернативу, то  $\mu_0 > 0$  или  $\mu_0 < 0$ )

Б) Распределение расчетной статистики:

$$T = \frac{\bar{X} - \mu_0}{\sqrt{\hat{\sigma}^2/n}} \sim t(n-1)$$

Эта статистика была выбрана, так как при больших  $n$  распределение Стьюдента почти не отличается от нормального.

Найдем критическое значение функции:

$$T = \frac{7.590100102044744}{\sqrt{170.7293705524155/1000}} = 18.369332869233308$$

Уровень значимости 10%

$\alpha = 0.1$

Тогда найдем  $z_{95}$  и  $z_5$

$$t_{999,0.05} = -1.6463803454275356$$

$$t_{999,0.95} = 1.646380345427535$$

Критическое значение 18.369332869233308 выходит за пределы интервала (-1.6463803454275356, 1.646380345427535)

**Н<sub>0</sub> тогда отвергается в пользу Н<sub>1</sub>.**

### Задание 6.

*Проверьте гипотезу о равенстве математических ожиданий двух выборок, предполагая равенство дисперсий.*

*Используйте двустороннюю альтернативу и уровень значимости 10%.*

*а) сформулируйте основную и альтернативную гипотезы;*

*б) выпишите расчетную статистику. Почему была выбрана именно такая статистика?*

$n = 500, m = 500$

$\bar{x} = 7.672579869842593$

$\bar{y} = 7.507620334246894$

$\widehat{\sigma_x^2} = 166.0071180387518$

$\widehat{\sigma_y^2} = 175.79376609323836$

А) Сформулируем гипотезы

Н<sub>0</sub>:  $\mu_0 = \mu_1$

Н<sub>1</sub>:  $\mu_0 \neq \mu_1$  (так как используем двустороннюю альтернативу, то  $\mu_0 > 0$  или  $\mu_0 < 0$ )

Б) Расчетная статистика:

$$T = \frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{\left(\frac{1}{n} + \frac{1}{m}\right) \left( \frac{n-1}{n+m-2} \hat{\sigma}_X^2 + \frac{m-1}{n+m-2} \hat{\sigma}_Y^2 \right)}} \sim t(n+m-2)$$

Это две независимые нормальные одинаково распределённые случайные величины с математическими ожиданиями  $\mu_0$  и  $\mu_1$  и дисперсиями  $\sigma^2_0$  и  $\sigma^2_1$ , и на основании данных об их реализациях нужно построить доверительный интервал для величин  $d = X_i - Y_i$ . Эти величины также образуют выборку из нормальной генеральной совокупности с математическим ожиданием  $E(d) = \mu_0 - \mu_1 = 0$ . Таким образом, задача построения доверительного интервала для разности математических ожиданий сводится к задаче оценивания интервала для математического ожидания  $d$ , а это уже приводится к  $t(n-1)$ . Тогда расчетная статистика:

$$T = \frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{\left(\frac{1}{n} + \frac{1}{m}\right) \left( \frac{n-1}{n+m-2} \hat{\sigma}_X^2 + \frac{m-1}{n+m-2} \hat{\sigma}_Y^2 \right)}} \sim t(n+m-2)$$

Уровень значимости 10%, используем двустороннюю альтернативу

$\alpha = 0.1$

Тогда найдем  $z_{95}$  и  $z_5$

$t_{998,0.05} = -1.6463803454275356$

$t_{998,0.95} = 1.646380345427535$

$T = 0.04190924051968376$

Критическое значение 0.04190924051968376 не выходит за пределы интервала (-1.6463818766348761, 1.6463818766348755)

Не отвергаем гипотезу Н<sub>0</sub>

### Задание 7.

*Проверьте гипотезу о равенстве дисперсий двух выборок.*

Используйте двустороннюю альтернативу и уровень значимости 10%.

а) сформулируйте основную и альтернативную гипотезы;

б) выпишите расчетную статистику. Почему была выбрана именно такая статистика?

А) Гипотезы:

$$H_0: \widehat{\sigma_x^2} = \widehat{\sigma_y^2}$$

$$H_1: \widehat{\sigma_x^2} \neq \widehat{\sigma_y^2}$$

Б) Расчетная статистика:

$$T = \frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}{\frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2} \sim F(n-1, m-1)$$

Так как параметры матожидания нам не известны, а F-распределение основано на дополнительных предположениях о независимости и нормальности выборок данных, используем это распределение.

Область, в которой гипотеза  $H_0$  не отвергается:  $[F_{n-1, m-1; \alpha/2}; F_{n, m; 1-\alpha/2}]$

$$F_{n-1, m-1; \alpha/2} = 0.8629418796107595$$

$$F_{n, m; 1-\frac{\alpha}{2}} = 1.1586553765546113$$

$$T = 0.944328810560348$$

Критическое значение 0.944328810560348 не выходит за пределы интервала (0.8629418796107595, 1.1586553765546113)

Не отвергаем гипотезу  $H_0$

## Задание 8.

Проверьте гипотезу о равенстве долей единиц в двух выборках.

Используйте двустороннюю альтернативу и уровень значимости 10%.

а) Сформулируйте основную и альтернативную гипотезы.

б) Какие предположения должны быть сделаны о сформированных выборках для проверки и такой гипотезы?

$$\bar{x} = \frac{(\text{кол} - \text{во единиц})}{500}$$
$$\bar{y} = \frac{(\text{кол} - \text{во единиц})}{500}$$

$$\bar{x} = 0.506$$

$$\bar{y} = 0.508$$

А) Гипотеза:

$$H_0: p_x = p_y$$

$$H_1: p_x \neq p_y$$

Б) Предположим, что это распределение Бернулли. Мы должны проверить, что доли единиц равны. Доверительный интервал для  $p$  – частный случай доверительного интервала для  $\mu$ . Выборочное среднее в этом случае есть выборочное отношение  $\hat{p}$ .

Расчетная статистика:

$$T = \frac{\bar{X} - \bar{Y} - (p_x - p_y)}{\sqrt{\frac{\bar{X}(1-\bar{X})}{n} + \frac{\bar{Y}(1-\bar{Y})}{m}}} \sim N(0; 1)$$

Уровень значимости 10%

Двусторонняя альтернатива

Тогда найдем  $z_5$  и  $z_{95}$

$$Z_5 = -1.6448536269514729$$

$$Z_{95} = 1.6448536269514722$$

$$T = -0.06325187870752942$$

Критическое значение  $-0.06325187870752942$  не выходит за пределы интервала  $(-1.6448536269514729, 1.6448536269514722)$

Не отвергаем гипотезу о равенстве долей единиц